

Retour d'intégration — export NeoMundi ControlTower × reconstruction FactNotebook

Pilote : PubMedQA, 5 générations GPT-4o gouvernées. **Objet** : retour technique de FactNotebook (tiers reconstruisant l'évidence) sur les exports JSON de NeoMundi ControlTower, en réponse au questionnaire de Sébastien Favre. **Niveau** : expérience d'intégration et de reconstruction (sortie / doctrine) — aucun mécanisme interne du moteur n'est décrit.

1–2. Clarté de la structure JSON & simplicité d'ingestion

La structure JSONL — un enregistrement par génération gouvernée, avec un typage d'événement explicite (mesure runtime vs flag de sur-affirmation) — est claire et directement exploitable. L'ingestion a été **déterministe** via un connecteur dédié : aucun retraitement manuel n'a été nécessaire pour passer de l'export à des observations attribuées.

3. Difficultés / ambiguïtés / retraitements

Peu, mais un point mérite d'être signalé : l'**identité du modèle** est déclarée dans l'export, mais la couche `govern` a enregistré `govern_model_raw='unknown'` (`observed_model_source='runner_declared_fallback'`). L'identité est donc **auto-déclarée (A2)**, non confirmée indépendamment — ce qui m'a conduit à marquer l'aspect « modèle observé » en **NON ÉVALUABLE** plutôt qu'à surinterpréter. Par ailleurs, la sémantique exacte de certaines échelles (`severity`, `category` du flag, seuils de `g_final`) a demandé un peu d'inférence.

4. Documentation suffisante pour reconstruire sans échange ?

En grande partie, oui : j'ai pu reconstruire les objets de gouvernance des Art. 9/12/15 à partir du seul export. Les rares points d'inférence (ci-dessus) sont exactement ceux qu'une **documentation de champ explicite** — ou le contrat d'interopérabilité à venir — supprimerait.

5. Champs / métadonnées les plus utiles

Par ordre : (a) le **flag de sur-affirmation indépendant** — un témoin distinct du modèle ; (b) les **identifiants + horodatages ISO par génération** (traçabilité) ; (c) la **décision de gouvernance** et les signaux runtime (stabilité, cohérence, hallucination factuelle) ; (d) `timestamp_present`, qui permet de distinguer honnêtement un horodatage réel d'une absence.

6. Manques / à expliciter pour les prochains exports

- Une **identité de modèle confirmée indépendamment** (pour ne pas forcer l'Art. 12b en NON ÉVALUABLE) ;
- un **schéma de champs versionné et explicite** (le contrat d'interop le couvrira) ;
- si possible, un **signal d'événement de supervision/approbation humaine** en aval (Art. 14) : absent d'un export runtime, il reste NON ÉVALUABLE ;
- la **sémantique documentée** des échelles `severity` / `category`.

(La gouvernance des **données d'entraînement** — Art. 10 — n'est structurellement pas dans un export runtime : c'est une frontière, pas un défaut.)

7. Apport d'une mesure runtime indépendante — concrètement

Décisif. Comme les signaux ControlTower sont produits par un **témoin distinct du modèle évalué**, j'ai pu les traiter comme des observations **indépendantes (A3)** plutôt que comme de l'auto-déclaration. Concrètement : le flag de sur-affirmation m'a permis de reconstruire une **tension Art. 15 sans construire mon propre détecteur**, et la décision + les signaux runtime ont fourni une **base comportementale indépendante**. Résultat mesurable : une **part indépendante de 8/9 (89 %)** — l'essentiel du poids probatoire provient d'un témoin indépendant, pas de l'auto-rapport du système.

8. Sans les observations NeoMundi ?

Je n'aurais disposé que de l'**auto-déclaration du modèle (A2)**. Et surtout : **instrumenter moi-même le comportement runtime** (stabilité, cohérence, hallucination) **n'entre pas dans le périmètre de FactNotebook** — ce n'est pas notre rôle, et nous ne le ferions pas. FactNotebook **reconstruit** à partir d'observations ; il ne les **produit** pas. Sans une source de mesure indépendante, la **couche A3 n'existerait tout simplement pas** pour nous, et la reconstruction reposerait sur l'auto-rapport (A2) — ce qui plafonne l'assurance atteignable. C'est précisément pourquoi un instrument de mesure indépendant comme NeoMundi est **nécessaire et complémentaire**, et non quelque chose que FactNotebook chercherait à remplacer.

9. Robustesse pour une traçabilité exploitable par un tiers

Largement suffisante : chaque génération porte un identifiant de requête/trace et un horodatage ISO, ce qui permet de **rattacher les observations à des générations précises, re-dérivables par un tiers**. Seule réserve : `timestamp_present` a montré que l'horodatage n'est pas toujours présent — je l'ai **représenté honnêtement** plutôt que supposé. Le contrat d'interop (versioning + règles de compatibilité) achèvera cette robustesse.

10. Distinction observation runtime / reconstruction / décision d'assurance

Les données **soutiennent proprement** la séparation : ControlTower **mesure** (il ne rend pas de verdict), FactNotebook **dérive** des objets de gouvernance sous politique déclarée, et la **décision d'assurance** reste à une autorité humaine. Le fait que ControlTower rapporte du comportement — et non des verdicts — est précisément ce qui rend ses signaux propres à être traités comme des observations.

Synthèse (≈10 lignes)

L'intégration des données NeoMundi a été simple et déterministe. Sa valeur décisive tient à une propriété : l'export fournit un **témoin runtime indépendant** — des signaux produits par autre chose que le modèle évalué. C'est exactement ce qui permet à un tiers de reconstruire des objets de gouvernance à un **grade d'indépendance élevé (A3)** au lieu de dépendre de l'auto-rapport. Les principaux manques — identité de modèle confirmée, canal de supervision humaine, schéma de champs explicite — sont pour l'essentiel des **frontières honnêtes**, que le contrat d'interopérabilité viendra en grande partie lever. Au fond, le pilote montre **deux instruments interopérables** aux responsabilités distinctes : NeoMundi **mesure**, FactNotebook **reconstruit** ce qu'un tiers peut légitimement établir.

Contrat JSON d'interopérabilité — ce qu'il aurait changé

Il aurait supprimé mes rares étapes d'**inférence** (signification et version des champs) et rendu l'ingestion **stable par contrat entre versions** — de sorte que la re-dérivation tienne même quand

l'export évolue. Il m'aurait aussi permis d'**affirmer** la compatibilité au niveau des champs au lieu de l'inférer. Je serai heureux de le relire, dès qu'il sera disponible, du point de vue des besoins d'une intégration tierce comme celle de FactNotebook.

Usage : toute citation publique directe de ce document est soumise à validation préalable de Patrick (accord Patrick × Sébastien). Document réutilisable comme note technique du pilote NeoMundi × FactNotebook v1.0.